

LATVIJAS UNIVERSITĀTE
EKSAKTO ZINĀTŅU UN TEHNOLOĢIJU FAKULTĀTE
DATORIKAS NODAĻA

**Statistikas datu pārveide un publicēšana atvērto
saistīto datu formā**

Autors: Niklāvs Pauls Strazdiņš
Studentu apliecības Nr.: ns22033
Darba vadītājs: Uldis Bojārs

RĪGA 2025

ANOTĀCIJA

Šī kursa darba mērķis ir izstrādāt un praktiski pārbaudīt metodoloģiju statistikas datu pārveidei un publicēšanai atvērto saistīto datu formā, izmantojot RDF Data Cube standartu. Darbā aplūkoti atvērto saistīto datu un semantiskā tīmekļa pamatprincipi, RDF datu modelis un statistikas datu semantiskās modelēšanas pieeja.

Darba ietvaros izstrādāta metodoloģija, kas aptver datu kopas atlasīšanu un analīzi, dimensiju, rādītāju un atribūtu noteikšanu, klasifikatoru izmantošanu un semantisko sasaistīšanu, kā arī datu publicēšanu tīmeklī. Metodoloģijas praktiskā pielietošana demonstrēta, pārveidojot Centrālās statistikas pārvaldes atvērto datu kopu “Iedzīvotāju skaits pēc tautības” RDF Data Cube formātā. Praktiskajā realizācijā statistiskie novērojumi tika modelēti kā semantiski objekti, sasaistot tos ar laika, teritorijas un tautības dimensijām, kā arī ar nacionālajiem klasifikatoriem ATVK_2021 un TAUT_2016, izmantojot SKOS standartu.

Rezultātā izveidota semantiski strukturēta statistikas datu kopa, kas publicēta kā statiska RDF datne ar URI. Darba rezultāti apliecina, ka RDF Data Cube standarts ir praktiski piemērots daudzdimensionālu statistikas datu publicēšanai atvērto saistīto datu formā arī bez sarežģītas servera infrastruktūras, nodrošinot datu semantisko precizitāti.

Atslēgvārdi: atvērtie saistītie dati, semantiskais tīmeklis, RDF, RDF Data Cube, statistikas dati, klasifikatori

ABSTRACT

The aim of this course paper is to develop and practically evaluate a methodology for transforming and publishing statistical data as linked open data using the RDF Data Cube standard. The paper examines the fundamental principles of linked open data and the Semantic Web, the RDF data model, and approaches semantic modelling of statistical data.

A methodology is proposed that covers dataset selection and analysis, identification of dimensions, measures and attributes, use of classifications and semantic linking, as well as data publication on the Web. The practical application of the methodology is demonstrated by transforming the open dataset “Population by ethnicity” published by the Central Statistical Bureau of Latvia into an RDF Data Cube representation. In the practical implementation, statistical observations are modelled as semantic entities linked to time, territory and ethnicity dimensions, and semantically aligned with the national classifications ATVK_2021 and TAUT_2016 using the SKOS standard.

As a result, a semantically structured statistical dataset was created and published as a static RDF file with stable URIs. The results demonstrate that the RDF Data Cube standard is well suited for publishing multidimensional statistical data as linked open data even without complex server infrastructure, ensuring semantic accuracy.

Keywords: linked open data, Semantic Web, RDF, RDF Data Cube, statistical data, classifications

SATURS

APZĪMEJUMU SARAKSTS	5
IEVADS.....	7
1. STATISTIKAS DATI ATVĒRTO SAISTĪTO DATU KONEKSTĀ	8
1.1. Atvērtie saistītie dati un semantiskais tīmeklis	8
1.2. RDF kā datu reprezentācijas modelis.....	10
1.3. Statistikas datu semantiskā modelēšana.....	10
1.4. RDF Data Cube kā standarts statistikas datiem	12
2. METODOLOĢIJA STATISTIKAS DATU PĀRVEIDEI UN PUBLICĒŠANAI LOD FORMĀTĀ PĒC RDF DATA CUBE STANDARTA	14
2.1 Metodoloģijas izstrādes pamatojums un mērķis	14
2.2 Metodoloģijas posmi.....	15
2.3 Datu kopas atlase un analīze	17
2.4 Dimensiju, rādītāju un atribūtu noteikšana	18
2.5 Klasifikatoru izmantošana un semantiskā sasaistīšana	18
2.6 Datu publicēšana atvērto saistīto datu formātā	19
3. STATISTIKAS DATU PUBLICĒŠANA ATVĒRTO SAISTĪTO DATU FORMĀ.....	21
3.1 Datu kopas izvēle un tās raksturojums.....	21
3.2 RDF Data Cube struktūras izveide.....	22
3.3 Klasifikatoru integrācija un semantiskā sasaistīšana	23
3.4 Statistisko novērojumu ģenerēšana un datu serializācija	25
3.5 Datu publicēšana atvērto saistīto datu formātā	26
REZULTĀTI	28
SECINĀJUMI.....	29
IZMANTOTĀ LITERATŪRA	30
PIELIKUMI	32

APZĪMEJUMU SARAKSTS

ATVK_2021 - Latvijas administratīvo teritoriju un teritoriālā iedalījuma vienību klasifikators (2021. gada versija).

Attribute (atribūts)- papildu informācija par statistisko novērojumu vai mērījumu, kas nav uzskatāma par dimensiju vai rādītāju.

CSP - Centrālā statistikas pārvalde; Latvijas oficiālās statistikas iestāde.

CSV - *Comma-Separated Values*; tabulārs datu formāts, kurā dati ir strukturēti rindās un kolonnās, atdalīti ar speciālām rakstzīmēm.

DCAT - *Data Catalog Vocabulary*; semantiskais standarts datu kopu metadatu aprakstīšanai.

Dimension (dimensija) - statistiskā novērojuma konteksta pazīme, piemēram, laiks, teritorija vai kategorija.

LOD - *Linked Open Data* jeb atvērtie saistītie dati; pieeja datu publicēšanai, kas apvieno atvērtu pieejamību ar semantisku sasaisti tīmeklī, izmantojot URI un RDF.

Measure (rādītājs) - skaitliska statistiskā vērtība, kas raksturo pētāmo parādību.

qb:DataSet - RDF Data Cube datu kopa, kas apvieno statistisko novērojumu kopumu.

qb:DataStructureDefinition (DSD) - RDF Data Cube struktūras definīcija, kas nosaka pieļaujamās dimensijas, rādītājus un atribūtus datu kopā.

qb:Observation - RDF Data Cube novērojuma objekts, kas reprezentē vienu statistisko mērījumu konkrētā dimensiju kontekstā.

RDF - *Resource Description Framework*; W3C izstrādāts datu reprezentācijas modelis semantiskajam tīmeklim, kas balstās uz trijnieku struktūru (subjekts–predikāts–objekts).

RDF Data Cube - W3C standarts daudzdimensionālu statistikas datu publicēšanai RDF formātā, kas paredz novērojumu, dimensiju, rādītāju un klasifikatoru formālu nošķiršanu.

RDFS - *RDF Schema*; RDF paplašinājums, kas ļauj definēt klašu un īpašību hierarhijas un semantiskās attiecības.

SKOS - *Simple Knowledge Organization System*; W3C standarts jēdzienu, klasifikatoru un kodu sarakstu semantiskai modelēšanai.

SPARQL - *SPARQL Protocol and RDF Query Language*; vaicājumu valoda RDF datu atlasei un analīzei.

TAUT_2016 - Latvijas nacionālais tautību klasifikators (2016. gada versija).

Turtle - *Terse RDF Triple Language*; cilvēklasāms RDF serializācijas formāts.

URI - *Uniform Resource Identifier*; vienots resursu identifikators, kas nodrošina objektu viennozīmīgu identificēšanu tīmeklī.

XLSX - Microsoft Excel izklājlapu failu formāts, ko bieži izmanto statistikas datu publicēšanai.

XML - *eXtensible Markup Language*; strukturēts datu apmaiņas formāts, ko izmanto dažādās informācijas sistēmās.

XSD - *XML Schema Definition*; datu tipu standarts, ko RDF izmanto skaitlisko un citu vērtību tipizēšanai.

IEVADS

Mūsdienu digitālajā sabiedrībā arvien pieaug datu nozīme lēmumu pieņemšanā, pētniecībā un sabiedrības informēšanā. Īpaša loma šajā kontekstā ir statistikas datiem, kas atspoguļo sociālekonomiskos procesus, demogrāfiskās izmaiņas un citus būtiskus radītājus valsts un pašvaldības līmeņos. Statistikas datus plaši izmanto valsts pārvaldes iestādes, akadēmiskā vide, uzņēmumi un iedzīvotāji, tomēr šo datu pieejamība un iespējas tos izmantot ir ierobežotas.

Atvērtie saistītie dati (Linked Open Data) piedāvā pieeju, kas ļauj publicēt datus strukturētā, mašīnlasāma un semantiski saistītā formātā, nodrošinot to savstarpēju sasaisti un integrāciju ar citiem datu avotiem. Izmantojot semantiskā tīkla tehnoloģijas piemēram, RDF un SPARQL, statistikas datus iespējam ne tikai publicēt, bet arī sasaistīt ar klasifikatoriem, ģeogrāfiskiem datiem un citiem publiskiem resursiem, kas būtiski uzlabotu datu izmantošanas iespējas.

Šī kursa darba mērķis ir izstrādāt un aprakstīt metodiku statistikas datu pārveidei un publicēšanai atvērto saistīto datu formā, kā arī demonstrēt metodikas pielietojumu, izmantojot reālu statistikas datu kopu. Darba ietvaros tiks analizēti atvērtie dati un atvērtie saistītie dati, apskatīti izmantotie standarti un tehnoloģijas, kā arī praktiski realizēts datu pārveides process.

Darbs sastāv no ievada, trīs nodaļām, rezultātiem un secinājumiem.

Pirmajā darba nodaļā tiks apskatīts atvērto saistīto datu teorētiskais pamatojums – semantiskā tīmekļa pamatprincipi, RDF datu modelis, statistikas datu semantiskās modelēšanas īpatnības un RDF Data Cube standarta pielietojums statistikas datu publicēšanai saistīto atvērto datu formātā.

Otrajā darba nodaļā tiks apskatīta un izveidota metodoloģija statistikas datu publicēšanai atvērto saistīto datu formātā. Tiks ietverts datu atlases, modelēšanas, pārveides un publicēšanas posmi.


Darba trešajā daļā tiks sniegts praktisks pielietojums aprakstītajai metodoloģijai, izmantojot atvērto statistikas datu kopu “Iedzīvotāju skaits pēc tautības”, kas publicēta Latvijas atvērto datu portālā data.gov.lv Centrālās statistikas pārvaldes uzturēšanā [1]. Minētā datu kopa ir publiski pieejama un licencēta ar Creative Commons Attribution 4.0 International (CC BY 4.0) licenci, kas ļauj datus brīvi izmantot, pārveidot un publicēt atkārtoti, norādot avotu. Praktiskajā daļā veikta datu pārveide atvērto saistīto datu formā, demonstrējot metodoloģijas pielietojumu reālam statistikas datu piemēram.

1. STATISTIKAS DATI ATVĒRTO SAISTĪTO DATU KONEKSTĀ

1.1. Atvērtie saistītie dati un semantiskais tīmeklis

Semantiskais tīmeklis ir koncepts, kas paredz tīmeklī pieejamo informāciju strukturēt tā, ka tā ir mašīnlasāma un viegli sasaistāma ar citu informāciju. Atšķirībā no tradicionālā tīmekļa, kurā informācija galvenokārt tiek publicēta nestrukturētā vai vāji strukturētā formā, semantiskais tīmeklis balstās uz formāli definētām datu struktūrām un noteiktām informācijas nozīmēm, kas padara datus mašīnlasāmus un ļauj sasaistīt datu avotus [2].

Semantiskā tīmekļa koncepts praksē tiek realizēts, izmantojot vairāku savstarpēji saistītu slāņu kopumu, kas kopā veido vienotu arhitektūru. Tims Berns-Lī piedāvāja modeli ar nosaukumu Semantiskā tīmekļa kaudze (Semantic Web Stack), kura mērķis ir parādīt pamattehnoloģijas, kas nodrošina semantiskā tīmekļa darbību [3].



1.1 attēls Semantic Web Layer Cake [3]

Modeļa pamatā atrodas URI (Uniform Resource identifier) un Unicode, kas nodrošina objektu viennozīmīgu identificēšanu un starptautisku simbolu atbalstu. Virs tiem atrodas RDF slānis, kas nodrošina pamata datu apmaiņas modeli un veido semantiskā tīmekļa kodolu. Nākamajos slāņos tiek izmantotas RDF Schemas un ontoloģijas, kas ļauj definēt jēdzienu struktūru, hierarhijas un semantiskās attiecības. Datu izmantošanai un analīzei tiek izmantota SPARQL vaicājumu valoda, savukārt augstākajos slāņos konceptuāli tiek risināti loģikas,

pierādījumu un uzticamības jautājumi. Šajā darbā galvenā uzmanība pievērsta tiem slāņiem, kas ir saistīti ar datu publicēšanu un izmantošanu atvērto saistīto datu formā.

Viena no galvenajām semantiskā tīmekļa sastāvdaļām ir atvērtie saistītie dati. Atvērtie saistītie dati apvieno divus pamatprincipus: atvērtu datu pieejamību un datu savstarpēju sasaisti tīmeklī. Atvērto saistīto datu formāts paredz ka dati ir mašīnlasāmi, ko panāk izmantojot unikālus identifikatorus (URI), kas ļauj viennozīmīgi identificēt gan pašus datu objektus, gan to īpašības un savstarpējas attiecības [4].

Atvērtie saistītie dati bieži tiek raksturoti ar zvaigžņu modeli, kas apraksta datu atvērtības un sasaistes līmeņus. Šī modeļa ietvaros augstākais līmenis ir sasniegts tad, ja dati ir publicēti atvērtā formātā, tiek izmantoti URI objektu identificēšanai, ir sasaistīti ar citiem datu avotiem un ir pieejami atkārtotai izmantošanai bez būtiskiem ierobežojumiem [5]. Šāda pieeja veicina datu integrāciju starp dažādām sistēmām, kā arī uzlabo datu izmantojamību analītiķiem un pētniekiem.



1.2 attēls Piecu Zvaigžņu modelis [15]

Populārākais atvērto saistīto datu publicēšanas standarts ir RDF (Resource Description Framework), kas nodrošina vienotu datu reprezentācijas modeli. RDF ļauj jebkuru objektu raksturot ar 3 sastāvdaļām, ko sauc par trijnieku. Katru trijnieku veido subjekts-predikāts-objekts struktūra, tādējādi veidojot grafu, kurā dati ir savstarpēji saistīti. Šāds grafu modelis ļauj aprakstīt gan vienkāršas, gan sarežģītas attiecības starp dažādiem datu objektiem [6].

Atvērtie dati ir nozīmīgi publiskajā sektorā, kur statistikas datus iestādes publicē dažādos formātos un bieži arī ļoti sarežģīti ir tos sasaistīt. Publicējot statistikas datus atvērto saistīto datu formātā, ir iespējam nodrošināt šo datu semantisku savietojamību, padarot tos vieglāk integrējamus ar citiem datu avotiem un piemērotus automatizētai apstrādei. Tas veicinātu datu atkārtotu izmantošanu, pārskatāmību un uz datiem balstītu lēmumu pieņemšanu [7].

Semantiskais tīmeklis un atvērtie saistītie dati veido teorētisko pamatu pieejai, kurā dati tiek uztverti nevis kā izolētas tabulas un dokumenti, bet gan kā savstarpēji saistītu zināšanu tīkls. Šī pieeja ir piemērota statistikas datiem, jo tie strukturēti un tiem ir nepieciešamība pēc

sasaistes ar klasifikatoriem, laika un telpiskajiem rādītājiem (dimensijām), kas tiks aplūkots turpmākajās darba nodaļās.

1.2. RDF kā datu reprezentācijas modelis

Resursu aprakstīšanas ietvars (Resource Description Framework, RDF) ir W3C izstrādāts standarts, kas paredzēts strukturētai un semantiski bagātai datu reprezentācijai tīmeklī. RDF ir semantiskā tīmekļa pamattehnoloģija, uz kuras balstās liela daļa atvērto saistītie dati, nodrošinot vienotu un formāli definētu datu raksturošanas modeli [7]. Atšķirība no tradicionālajiem datu formātiem, piemēram CSV vai XML, RDF primārais mērķis nav tikai datu strukturēšana, bet arī to nozīmes un savstarpējo attiecību precīza aprakstīšana.

RDF datu modelis balstās uz trijnieka struktūru, kas sastāv no subjekta, predikāta un objekta. Subjekts identificē aprakstāmo resursu, predikāts – resursa īpašību vai attiecību, un objekts – vērtību. Šādi veidots trijnieks viedo orientētu grafu, kurā mezgli reprezentē resursus vai vērtības, bet malas – semantiskās attiecības starp tiem [8]

Būtiska RDF funkcija ir resursu identificēšana, izmantojot vienotus resursu identifikators (URI). URI izmantošana nodrošina, ka katrs datu objekts un jēdziens ir viennozīmīgi identificējams globālā mērogā, kas ir priekšnoteikums datu sasaistīšanai starp dažādiem avotiem. Tas ļauj dažādu organizāciju publicētos datus savstarpēji integrēt, neieviešot centralizētu datu pārvaldības mehānismu [5].


RDF pats par sevi nenosaka jēdzienu hierarhiju vai datu tipu ierobežojumus tādēļ datu semantiskai strukturēšanai tiek izmantots RDF Schema (RDFS) un ontoloģiju valodas piemēram, OWL. RDF Schema ļauj definēt klašu un īpašību hierarhijas, kā arī norādīt kādi resursi var būt konkrētu īpašību subjekti vai objekti. Iespēja norādīt kādi resursi var būt konkrētu īpašību subjekti vai objekti ir nozīmīga statistikas datu kontekstā, kur nepieciešams strukturēt dimensijas, rādītājus un klasifikatorus vienotā semantiskā modelī [9]

Statistikas datu reprezentācijā RDF ir priekšrocības salīdzinājumā ar tradicionāliem tabulu formātiem. Tabulā katra rinda un kolonna ir interpretējama tikai konteksta ietvaros, savukārt RDF modelī katrs novērojums, tā dimensijas un rādītāji ir aprakstīti kā atsevišķi semantiski elementi ar skaidru nozīmi. Tas ļauj statistikas datus izmantot elastīgāk, piemēram, kombinējot vairākus datu kopumus, pievienojot jaunus klasifikators vai analizējot datus dažādos griezumos bez sākotnējās struktūras pārveides [10].

1.3. Statistikas datu semantiskā modelēšana

Statistikas dati pēc būtības ir strukturēti un daudzdimensionāli, jo tie apraksta noteiktu parādību konkrētā laika, telpā pēc dažādām pazīmēm. Tradicionāli statistikas dati tiek attēloti

tabulu veidā, kur katra rinda atbilst novērojumam, bet kolonnas – pazīmēm vai rādītājiem. Tomēr tabulā šī struktūra balstās uz cilvēka interpretāciju, savukārt semantiskās modelēšanas mērķis ir šo struktūru formāli aprakstīt un padarīt mašīnlasāmu [11].




1.3 attēls Tabulāra datu struktūra [19]

Semantiskajā modelēšanā statistikas dati tiek aplūkoti kā novērojumu kopums, kur katrs novērojums raksturo konkrētās parādības vērtību noteiktā kontekstā. Šo kontekstu veido dimensijas, kas raksturo novērojumu analītisko “griezumu”, piemēram, laika periods, ģeogrāfiska teritorija vai kategorijas pazīme. Papildus dimensijām katram novērojumam tiek piešķirti rādītāji, kas satur skaitliskās vērtības, piemēram, iedzīvotāju skaitu vai procentuālo īpatsvaru. Šāda statistisko novērojumu interpretācija ir plaši izmantota semantiskā tīmekļa pieejā statistikas datu aprakstīšanai [11].

Būtiska statistikas datu semantikas modelēšanas sastāvdaļa ir arī klasifikatori, kas nodrošina vienotu vērtību aprakstu. Klasifikatori tiek izmantoti, lai definētu piemēram, tautības, administratīvās teritorijas vai citus statistikas iedalījumus. Semantiskajā modelī klasifikatori tiek uztverti kā atsevišķi jēdzieni ar definētu nozīmi. Tie palīdz veidot semantisku savietojamību starp dažādām statistikas datu kopām

Statistikas datu semantiskās modelēšanas procesā uzmanība ir jāpievērš novērojumu nepārprotamai interpretācijai. Katram novērojumam ir jābūt viennozīmīgi aprakstītam, skaidri norādot visas dimensijas, rādītājus un to metadatus. Tas ļauj novērst situācijas, kurās datu interpretācija ir atkarīga no tabulas virsrakstiem vai pavaddokumentācijas, un nodrošina iespēju datus automatizēti apstrādāt analizēt un savietot ar citiem semantiski strukturētiem datiem [11].



1.4. attēls Beatles RDF data [20]

Lai gan semantiskā modelēšanas pamatprincipi ļauj konceptuāli aprakstīt statistikas datus RDF formātā, praksē ir nepieciešams standartizēts ietvars, kas nodrošina standartizētu un daudzdimensionālu datu reprezentāciju. Šim nolūkam ir izstrādās RDF Data Cube standarts, kas piedāvā formālu modeli statistikas novērojumu, dimensiju, rādītāju un klasifikatoru aprakstīšanai, kura pielietojums statistikas datu publicēšanā tiks aplūkots nākamajā apakšnodaļā [11].

1.4. RDF Data Cube kā standarts statistikas datiem

Lai nodrošinātu savietojamu statistikas datu semantisko reprezentāciju, nepietiek ar vispārīgu RDF modeli. Statistikas dati ir daudzdimensionāli, un to aprakstam nepieciešams standartizēts ietvars, kas formāli definē novērojumus, dimensijas, rādītājus un klasifikatorus. Šādu ietvaru piedāvā RDF Data Cube standarts, kas ir izstrādāta kā W3C rekomendācija statistikas datu publicēšanai semantiskā tīmekļa vidē [11].

RDF Data Cube standarts balstās uz to, ka katrs statistikas novērojums tiek modelēts kā atsevišķs semantisks objekts, kuram ir skaidri definētas dimensijas un rādītāji. Dimensijas raksturo novērojuma kontekstu – laika periods, ģeogrāfiskā teritorija, savukārt rādītāji satur skaitliskās vērtības, kas raksturo analizējamo notikumu [11]. Šāda pieeja ļauj statistikas datus interpretēt viennozīmīgi un neatkarīgi no tā sākotnējās tabulārās struktūras tā, kā aprakstīts statistikas datu semantiskās publicēšanas pētījumos [11].

Svarīga RDF Data Cube sastāvdaļa ir datu struktūras definīcija (Data structure definition), kas nosaka, kādas dimensijas un rādītāji ir pieļaujami konkrētajā datu kopā. Šī funkcionalitāte nodrošina datu viennozīmīgumu un atvieglo dažādu statistikas datu kopu savstarpēju salīdzināšanu un integrāciju. Papildus šim RDF Data Cube paredz klasifikatoru

izmantošanu kā atsevišķus semantiskus objektus, kas atvieglo sasaisti ar citiem datu avotiem [11].

RDF Data Cube standarts ir plaši izmantots oficiālās statistikas kontekstā, tostarp Eiropas savienības institūcijās un atsevišķās nacionālajās statistikas iestādēs, lai publicētu statistikas datus atvērto saistīto datu formā [12].

Var secināt, ka RDF Data Cube nodrošina starptautiski atzītu risinājumu statistikas datu semantiskai modelēšanai, apvienojot semantiskā tīmekļa pamatprincipus ar statistikas datu specifiskām. Tādējādi RDF Data Cube kalpo kā teorētiskais un praktiskais pamats statistikas datu pārveidei un publicēšanai atvērto saistīto datu formā, kas turpmāk darbā tiks izmantots metodoloģijas izstrādē un praktiskā piemēra realizācijā.

2. METODOLOĢIJA STATISTIKAS DATU PĀRVEIDEI UN PUBLICĒŠANAI LOD FORMĀTĀ PĒC RDF DATA CUBE STANDARTA

2.1 Metodoloģijas izstrādes pamatojums un mērķis


Statistikas datu publicēšanai atvērto saistīto datu formā ir iespējamās vairākas pieejas, sākot no vienkāršas datu konvertēšanas RDF formātā līdz specializētu semantisko standartu izmantošanai. Šī kursa darba ietvaros metodoloģijas izstrādē tika pieņemts lēmums balstīties uz RDF Data Cube, jo tas piedāvā strukturētu un starptautiski atzītu risinājumu daudzdimensionālu statistikas datu reprezentācijā [11].

Izvēlētajā metodoloģijā balstās uz pieņēmumu, ka statistikas datu publicēšanas kvalitāti nosaka ne tikai datu pieejamība, bet arī to semantiskā precizitāte un savietojamība ar citiem datu avotiem. Vienkārša RDF trijnieku ģenerēšana no tabulāriem datiem nenodrošina skaidru atšķirību starp dimensijām, rādītājiem un klasifikatoriem, kas statistikas datu gadījumā ir svarīgi analīzes veikšanai un datu atkārtotai izmantošanai. [11]

RDF Data Cube standarta izmantošana metodoloģijā ļauj formāli nošķirt:

- Statistikas novērojumus,
- novērojumu dimensijas,
- mērījumus un to vērtības,
- klasifikatorus un to semantiskās attiecības.

Šāda strukturēta pieeja nodrošina, ka katrs statistiskais novērojums ir interpretējam neatkarīgi no sākotnējā datu avota vai formāta, kā arī ļauj datus izmantot automatizētas analīzes un vaicājumu sistēmās [11].



2.1 attēls RDF Data Cube komponentes un to saites [11]

Metodoloģijas izstrādes procesā īpaša uzmanība tika pievērsta arī klasifikatoru lomai statistikas datu interpretācijā. Tā vietā, lai klasifikatoru vērtības saglabātu kā vienkāršas teksta vai koda vērtības, metodoloģija paredz to modelēšanu kā atsevišķus semantiskus objektus, izmantojot SKOS standartu. Šāda pieeja ļauj veidot sasaistes ar oficiālajiem klasifikatoriem un nodrošina datu semantisko savietojamību ar citiem statikas resursiem [4].

Izstrādātās metodoloģijas mērķis ir izveidot praktiski pielietojamu un atkārtojamu statistikas datu publicēšanas procesu, kas:

- ir balstīts uz starptautiski atzītiem semantiskā tīmekļa standartiem,
- nodrošina datu viennozīmīgumu,
- ļauj datus publicēt kā atvērtus saistītus datus bez specifiskā infrastruktūras standartiem.

Metodoloģijā ir veidota tā, lai tā būtu pielāgojama arī citām statistikas datu kopām, saglabājot tās pamatprincipus un mainot tikai konkrētos datu elementus, piemēram, dimensijas vai klasifikatorus.

2.2 Metodoloģijas posmi

Izstrādātā metodoloģija statistikas datu publicēšanai atvērto saistīto datu formātā ir strukturēta vairākos secīgos posmos, kas nodrošina pāreju no sākotnējiem tabulārajiem datiem līdz semantiski strukturētai RDF Data Cube datu kopai. Posmu sadalījums ļauj skaidri pamatot

katru veikto darbību un nodrošina metodoloģijas atkārtojamību arī citu statistikas datu kopu gadījumā.

Pirmajā posmā tiek izvēlēta statistikas datu kopa, kas atbilst atvērto daru principiem un ir piemērota semantiskai modelēšanai. Šajā posmā tiek analizēta datu struktūra identificētas galvenās kolonnas, noteikta laika dimensijas formāts un izvērtēta klasifikatoru izmantošana. Šī analīze ir nepieciešama, lai novērstu nekorektu datu interpretāciju turpmākajos posmos un nodrošinātu atbilstību RDF Data Cube prasībām [11].

Otrajā posmā tiek noteikti galvenie statistiskā novērojuma elementi. Metodoloģijā tiek nošķirtas:

- dimensijas kas raksturo novērojuma kontekstu,
- rādītāji, kas satur skaitliskās vērtības,
- atribūti, kas nodrošina papildu informāciju par mērījumiem.

Šāds sadalījums ir būtisks RDF Data Cube standarta pielietošanā, jo tas nodrošina viennozīmīgu datu interpretāciju un ļauj veikt daudzdimensionālu analīzi neatkarīgi no sākotnējās datu struktūras [11].

Trešajā posmā tiek apstrādāti statistikas datus izmantotie klasifikatori. Metodoloģijā paredz klasifikatoru modelēšanu kā atsevišķus semantiskus objektus, izmantojot SKOS standartu. Šajā posmā tiek veidotas arī sasaistes ar oficiālajiem vai ārējiem klasifikatoriem, izmantojot atbilstības attiecības, izmantojot atbilstības attiecības, piemēram, skos:exactMatch. Šāda pieeja uzlabo datu savietojamību un veicina to integrāciju ar citiem statistikas datu avotiem [4].

Ceturtajā posmā tiek veidota datu struktūras definīcija (Data Structure Definition), kas nosaka, kādas dimensijas, rādītāji un atribūti ir pieļaujami konkrētajā datu kopā šī struktūra kalpo kā formāls ietvars visiem statistiskajiem novērojumiem un nodrošina datu viennozīmīgumu visā datu kopā. Datu struktūras definēšana ir svarīga, lai nodrošinātu datu korektumu un atbilstību RDF Data Cube specifikācijai [11].

Piektajā posmā tiek realizēta datu pārveide no tabulārā formāta uz RDF trijniekiem, balstoties uz iepriekš definēto struktūru. Katrs statistiskais novērojums tiek reprezentēts kā atsevišķs semantisks objekts ar atsaucēm uz dimensijām, rādītājiem un klasifikatoriem. Šajā posmā uzmanība tiek pievērsta vienotu URI izmantošanai, kas nodrošina datu identificējamību un sasaistamību tīmeklī [5].

Noslēdzošajā sestajā posmā izveidotā RDF datu kopa tiek publicēta tīmeklī, nodrošinot tās pieejamību izmantošanai. Metodoloģija paredz, ka datu publicēšanai nav obligāti nepieciešams SPARQL galapunkts, taču struktūrai ir jābūt tādai, lai tā būtu piemērota

vaicājumu veikšanai gan lokāli, gan servera vidē. Šāda pieeja nodrošina elastību datu publicēšanas veidos un atbilst atvērto saistīto datu principiem [5].

2.3 Datu kopas atlase un analīze

Izstrādātās metodoloģijas ietvaros datu kopas atlase ir uzskatāma par būtisku priekšnosacījumu korektai statistikas datu publicēšanai atvērto saistīto datu formā. Datu kopai ir jābūt piemērotai daudzdimensionālai modelēšanai un jānodrošina pietiekama semantiskā informācija, lai to varētu interpretēt neatkarīgi no sākotnējā formāta.

Metodoloģijā paredzēts, ka datu kopai ir jāatbilst atvērto datu principiem, tostarp tai jābūt publiski pieejamai un licencētai atkārtotai izmantošanai. Licences izvērtēšana ir nepieciešama, jo atvērto saistīto datu publicēšana paredz datu brīvu pieejamību un tālāku izmantošanu citās sistēmās [5]. Ja datu kopa neatbilst šiem nosacījumiem, tās izmantošana atvērto saistīto datu publicēšanai ir ierobežota.

Atlases procesā jāņem vērā arī datu struktūra. Metodoloģija paredz, ka piemērota statistikas datu kopa satur skaidri identificējamās analītiskās pazīmes, kas potenciāli atbilst RDF Data Cube elementiem. Šīs pazīmes ietver laika dimensiju, vismaz vienu kategorisku vai telpisku dimensiju un vienu vai vairākus skaitliskus rādītājus. Šāda struktūra ļauj veidot statistiskos novērojumus, kas atbilst RDF Data Cube standarta prasībām [11].

Datu kopas sākotnējā analīze metodoloģijā ietver kolonnu nozīmes izvērtēšanu un to interpretāciju statistikas datu kontekstā. Šajā posmā netiek veikta datu pārveide, bet gan noteiktas, kādas datu kopas sastāvdaļas, interpretācija kā dimensijas, rādītāji vai atribūti. Šāda analīze ir būtiska, lai novērstu semantiskas kļūdas, kas var rasties, ja tabulārās vērtības tiek mehāniski pārnestas RDF formātā bez skaidras nozīmes definēšanas [11].

Papildu uzmanība metodoloģijā tiek pievērsta klasifikatoru klātbūtnei datu kopā. Ka datu kopa izmanto kodētas vērtības, piemēram teritoriju vai kategoriju kodus, metodoloģija paredz izvērtēšanu attiecībā uz oficiālajiem vai plaši izmantotiem klasifikatoriem. Šāda izvērtēšana ir priekšnoteikums turpmākai semantiskai sasaistīšanai un datu savietojamības nodrošināšanai [4].

Tādējādi datu kopas atlases analīzes posms metodoloģijā kalpo kā sagatavošanās fāze, kurā tiek noteikta datu piemērotības semantiskai publicēšanai un tiek identificēti galvenie elementi, kas tiks izmantoti turpmākajos metodoloģija posmos. Šis posms nodrošina strukturētu pamatu datu modelēšana un samazina risku nepareizi interpretēt statistisko informāciju atvērto saistīto datu kontekstā.

2.4 Dimensiju, rādītāju un atribūtu noteikšana

Statistikas datu semantiskā modelēšana balstās uz skaidru novērojuma struktūras definēšanu, kurā tiek nošķirti dažādi datu elementi atbilstoši to lomai statistiskajā analīzē. Izstrādātajā metodoloģijā dimensiju, rādītāju un atribūtu noteikšana tiek uzskatīta par būtisku posmu, jo no šīs izvēles ir atkarīga datu interpretējamība un atbilstība RDF Data Cube standarta prasībām.

Metodoloģijā paredzēts, ka dimensijas raksturo statistiskā novērojuma analītisko kontekstu. Tas nosaka, par ko, kur un kad attiecas konkrētais novērojums. Dimensijas parasti ietver laika aspektu, telpisko vai administratīvo iedalījumu, kā kategoriskas pazīmes. Dimensiju izvēlei jānodrošina, ka katrs statistiskais novērojums ir viennozīmīgi identificējams un nošķirams no citiem novērojumiem datu kopas ietvaros [11].

Rādītāji metodoloģijā tiek definēti kā skaitliskās vērtības, kas raksturo pētāmo parādību. Tie atspoguļo statistisko mērījumu rezultātus un tiek saistīti ar attiecīgajām dimensijām. Metodoloģija paredz, ka rādītājiem jābūt kvantitatīviem un interpretējamiem neatkarīgi no datu kopas konteksta, kas ir svarīgi daudzdimensionālu statistikas datu analīzē [12].

Papildus dimensijām un rādītājiem metodoloģijā tiek paredzēta atribūtu izmantošana gadījumos, kad nepieciešams papildināt statistisko novērojumu ar papildu informāciju. Atribūti var tikt izmantoti, lai norādītu mērījumu kvalitāti, piezīmes, datu precizitāti vai citus aspektus, kas nav uzskatāmi par atsevišķām dimensijām vai rādītājiem. Šāda nošķiršana ļauj saglabāt datu struktūras skaidrību un novērst semantisku pārslodzi datu modelī [11].

Dimensiju, rādītāju un atribūtu noteikšanā metodoloģijā balstās arī uz oficiālās statistikas konceptiem, kas ir plaši izmantoti starptautiskajā statistikā, piemēram, SDMX (Statistical Data and Metadata eXchange) informācijas modelī. SDMX pieeja paredz līdzīgu nošķiršanu starp statistiskā novērojuma kontekstu un mērījumu vērtībām, kas nodrošina savietojamību starp dažādiem statistikas standartiem un veicina datu integrāciju [13].

Izstrādātajā metodoloģijā tiek uzsvērts, ka dimensiju, rādītāju un atribūtu izvēle nedrīkst būt mehāniska. Katram datu elementam ir jābūt skaidrai semantiskai lomai, un tā izvēlei jābūt pamatotai ar statistikas datu interpretācijas vajadzībām. Šāda pieeja nodrošina, ka iegūtā RDF Data Cube struktūra ir ne tikai tehniski korekta, bet arī piemērota analītiskai izmantošanai atvērto saistīto datu vidē.

2.5 Klasifikatoru izmantošana un semantiskā sasaistīšana

Statistikas datu publicēšana klasifikatoriem ir svarīga, jo tie nodrošina vienotu vērtības interpretāciju dažādās datu kopās. Izstrādātajā metodoloģijā klasifikatori tiek uzskatīti par

neatņemamu statistisko datu semantiskās modelēšanas sastāvdaļu, jo tie nosaka kādā veidā kategoriskas vērtības tiek interpretētas un savstarpēji salīdzinātas.

Metodoloģijā paredzēts, ka statistikas datus izmantotās kodētās vai kategoriskās vērtības netiek modelētas kā vienkāršas teksta virknes vai skaitļi, bet gan kā atsevišķi semantiski objekti. Šāda pieeja ļauj piešķirt šīm vērtībām skaidru nozīmi un nodrošina atkārtotu izmantošanu citās datu kopās. Klasifikatoru modelēšana kā atsevišķu objektu kopas ir priekšrocība salīdzinājumā ar tradicionālu tabulāru datu publicēšanu [4].

Klasifikatoru semantiskai reprezentācija metodoloģijā tiek ieteikts izmantot SKOS (Simple Knowledge Organization System) standarts. SKOS nodrošina vienkāršu, bet pietiekami izteismīgu ietvaru jēdzienu, to apzīmējumu un savstarpējo attiecību aprakstīšanai. Šis standarts ir īpaši piemērots statistikas klasifikatoriem, jo tas ļauj strukturēt kodu sarakstus, saglabājot to semantisko nozīmi un paplašināmību [14].

Metodoloģija paredz, ka katrs klasifikators tiek organizēts kā atsevišķa jēdzienu shēma (ConceptScheme), kurā katra vērtība tiek modelēta kā jēdziens (Concept). Šāda strukturēšana nodrošina skaidru klasifikatora robežu definēšanu un ļauj dažādos kontekstos izmantot vienas un tās pašas vērtības bez nozīmes zaudēšanas [14].

Svarīgs metodoloģijas aspekts ir arī semantiskā sasaistīšana ar ārējiem vai oficiāliem klasifikatoriem. Ja datu kopā izmantotās vērtības atbilst plašāk lietotiem statistikas klasifikatoriem, metodoloģija paredz to sasaisti izmantojot semantiskās atbilstības attiecības, piemēram, skos:exactMatch. Āda sasaistīšana veicina datu savietojamību un ļauj automatizēti integrēt datus no dažādiem avotiem bez manuālas vērtību kartēšanas [5].

Metodoloģija tiek uzsvērts, ka semantiskā sasaistīšana ir jāveic apzināti un pamatoti. Ne visas vērtības vienmēr ir pilnībā ekvivalentas, tāpēc klasifikatoru atbilstības ir jāizvērtē pirms semantisko saišu izveides. Nepamantota sasaistīšana var radīt kļūdainas interpretācijas un samazināt datu kvalitāti [14].

Klasifikatoru izmantošanas semantiskās sasaistīšanas posms metodoloģijā nodrošina pamatu statistikas datu savietojamībai un atkārtotai izmantošanai. Šī pieeja ļauj veidot statistikas datus kā savstarpēji saistītu resursu kopumu, kas ir gan piemērots analītiskai izmantošana, gan integrācijai plašākā atvērto saistīto datu ekosistēmā.

2.6 Datu publicēšana atvērto saistīto datu formātā

Statistikas datu pārveide RDF Data Cube formātā ir tikai viens no soļiem ceļā uz atvērto saistīto datu izmantošanu. Lai dati būtu uzskatāmi par pilnvērtīgi publicētiem atvērto saistīto datu formātā, metodoloģijā ir jāparedz arī datu publicēšanas principi un prasības, kas nodrošina to pieejamību, identificējamību un atkārtotu izmantošanu.

Metodoloģijā datu publicēšana tiek izprasta kā process, kurā semantiski strukturēti dati tiek padarīti pieejami tīmeklī, izmantojot stabilus un viennozīmīgus identifikatorus, Katram nozīmīgam resursam – datu kopai, novērojumam, dimensijai vai klasifikatoram – ir jābūt identificējamam ar URI, kas nodrošina iespēju uz šo resursu atsaukties no citām sistēmām [5]. Šī prasība ir būtiska, lai dati varētu funkcionēt kā savstarpēji saistītu resursu kopums.

Metodoloģijā tiek uzsvērts, ka datu publicēšanai atvērto saistīto datu formātā nav obligāti nepieciešama sarežģīta servera infrastruktūra. Datus var publicēt kā statiskus RDF failus, ja tie ir pieejami tīmeklī un atbilst semantiskā tīmekļa pamatprincipiem. Šāda pieeja ļauj samazināt publicēšanas sliekšni un padara metodoloģiju piemērotu arī nelielām institūcijām un individuāliem datu publicētājiem [4].

Vienlaikus metodoloģija paredz, ka publicētajiem datiem ir jābūt strukturētiem tā lai tie būtu piemērotu vaicājumu veikšana un automatizētai apstrādei. RDF Data Cube struktūra nodrošina, ka dati ir izmantojami SPARQL vaicājumos neatkarīgi no tā vai tie tiek analizēti lokāli vai servera vidē [11]. Šī pazīme ir svarīga statistikas datu analītiskai izmantošanai.

Svarīgs publicēšanas aspekts ir arī metadatu nodrošināšana. Datu kopai jābūt papildinātai ar pamata aprakstošo informāciju, piemēram, nosaukumu, aprakstu, valodu un struktūras definīciju. Metadati nodrošina datu saprotamību un ļauj lietotājiem novērtēt datu piemērotību konkrētiem izmantošanas mērķiem [12].

Datu publicēšana atvērto saistīto datu formātā nav uzskatāma par vienreizēju darbību. Publicētajiem datiem jābūt uzturamiem, paplašināmiem un savietojamiem ar nākotnes datu kopām. Šāda pieeja nodrošina, ka statistikas dati saglabā savu vērtību ilgtermiņā un var tikt izmantoti plašākā atvērto datu un semantiskā tīmekļa ekosistēmā.

3. STATISTIKAS DATU PUBLICĒŠANA ATVĒRTO SAISTĪTO DATU FORMĀ

Šajā darba daļā tiks demonstrēta 2. nodaļā izstrādātās metodoloģijas praktiskā pielietošana, pārveidojot tabulāra formāta statistikas datus par atvērtiem saistītajiem datiem saskaņā ar RDF Data Cube standartu. Praktiskā realizācija balstās uz atvērtu statistikas datu kopu “Iedzīvotāju skaits pēc tautības”, kas publicēta Latvijas atvērto datu portālā data.gov.lv Centrālās statistikas pārvaldes uzturēšanā [1], kas satur statistiskos novērojumus par iedzīvotāju skaitu un īpatsvaru pēc tautības, sadalījumā pa administratīvajām teritorijām un gadiem. Pārveides process tika realizētas ar Python skriptu, kurā metodoloģijas posmi tiek īstenoti secīgi: datu nolasīšana un analīze, dimensiju un rādītāju noteikšana, klasifikatoru piesaiste un sasaistīšana¹, RDF Data Cube struktūras definēšana, novērojumu ģenerēšana un rezultātu sterilizācija Turtle formātā.

3.1 Datu kopas izvēle un tās raksturojums

Izstrādātās metodoloģijas praktiskai pārbaudei un demonstrācijai tika izmantota Centrālās statistikas pārvaldes publicēta atvērto datu kopa “Iedzīvotāju skaits pēc tautības”², kas ir pieejama atvērto datu portālā data.gov.lv. Datu kopa ir publiski pieejama un licencēta ar Creative Commons Attribution 4.0 International (CC BY 4.0) licenci, kas ļauj datus brīvi izmantot, pārveidot un publicēt atkārtoti, norādot avotu.

Izvēlēta datu kopa satur statistisko informāciju par iedzīvotāju skaitu un procentuālo sadalījumu pēc tautības dažādos laika periodos un administratīvajās teritorijās. Šāda struktūra nodrošina daudzdimensionālu skatījumu uz statistiskajiem datiem un ir piemērota RDF Data Cube standart pielietošanai, jo dati ir dabiski organizējami pēc vairākām pazīmēm.

Datu kopas pamatā esošie dati ir publicēti tabulārā formātā (CSV), kur katra rinda atbilst konkrētam statistiskam novērojumam, bet kolonnas raksturo novērojuma kontekstu un vērtības. Datu kopā ir ietvertas laika dimensijas vērtības (Gads), teritoriālās piederības kodi, tautību apzīmējumi, kā arī skaitliskie rādītāji, kas raksturo iedzīvotāju skaitu un to īpatsvaru procentos. Papildus galvenajiem rādītājiem datu kopā ir iekļauti arī palīglauki, kas satur papildu informāciju vai piezīmes par mērījumiem.

Svarīga datu kopas iezīme ir kodētu vērtību izmantošana, piemēram teritoriju un tautību identificēšanai. Šie kodi ir saistāmi ar oficiālajiem statistikas klasifikatoriem, kas nodrošina

¹ <https://github.com/NiklavsPS/tautiba-rdf-datacube>

² <https://data.gov.lv/dati/lv/dataset/tautiba/resource/ac7b0734-bba7-4295-a81a-1eb635d722bc>

iespēju veidot semantiskas sasaistes un palielina datu savietojamību ar citām statistikas datu kopām. Šī īpašība ir svarīga atvērto saistīto datu kontekstā, jo ļauj paplašināt vienas datu kopas robežas un veidot integrējamus statistikas resursus.

Izmantotā datu kopa ir piemērota metodoloģija praktiskai demonstrēšanai vairāki iemeslu dēļ. Pirmkārt, tā ietver vairākas neatkarīgas dimensijas, kas ļauj parādīt statistisko novērojumu semantisko struktūru. Otrkārt, datu kopā ir gan absolūtie, gan relatīvie rādītāji, kas ļauj demonstrēt vairāku mērījumu izmantošanu vienā RDF Data Cube struktūrā. Treškārt, datu publiskā pieejamība un skaidra licence nodrošina iespēju datus publicēt atkārtoti atvērto saistīto datu formātā.

Tādējādi izvēlēta datu kopa kalpo kā reprezentatīvs piemērs oficiālajiem statistikas datiem un nodrošina piemērotu pamatu izstrādātās metodoloģijas praktiskai pielietošanai un novērtēšanai.

3.2 RDF Data Cube struktūras izveide

RDF Data Cube struktūras izveide praktiskajā piemērā tika realizēta, izstrādājot Python skriptu³. Skripts pārveido tabulārus statistikas datus RDF formātā atbilstoši RDF Data Cube standartam. Skripts tika izstrādāts tā, lai strukturēšanas loģika būtu nodalīta no datu apstrādes, nodrošinot risinājuma pārskatāmību un atkārtojamību.

Praktiskajā realizācijā RDF Data Cube struktūra tiek definēta izmantojot rdflib bibliotēku. Skripta sākumdaļā tiek deklarētas izmantotās namespaces, tostarp qb, skos, rdfs un dcterms, kas tiek izmantotas gan datu struktūras definēšanai, gan metadatu pievienošanai. Šāda pieeja ļauj vienā veidā pārvaldīt RDF elementus un izvairīties no nekonsekventas URI izmantošanas.

Datu kopas un datu struktūras definīcija tiek izveidota kā atsevišķi RDF resursi (qb:DataSet un qb:DataStructureDefinition), kuru skripts savstarpēji sasaista. Šajā posmā tiek realizēta viena no būtiskajām RDF Data Cube prasībām – katrai datu kopai ir tieši viena struktūras definīcija, kas nosaka atļautos komponentus. Skriptā šī struktūra tiek veidota pirms statistisko novērojumu ģenerēšanas, nodrošinot, ka visi novērojumi atbilst iepriekš definētajai shēmai.

Dimensiju, rādītāju un atribūtu pievienošana struktūras definīcijai skriptā ir realizēta ar atsevišķām funkcijām, kas ģenerē komponentu aprakstus (qb:component). Šī pieeja ļauj atkārtoti izmantot komponentu pievienošanas loģiku un vienkāršo struktūras paplašināšanu, piemēram, pievienojot jaunas dimensijas vai rādītājus. Katra dimensija tiek definēta kā

³ https://github.com/NiklavsPS/tautiba-rdf-datacube/blob/main/csv_to_datacube.py

qb:DimensionProperty, savukārt rādītāji – kā qb:MeasureProperty, kas atbilst RDF Data Cube specifikācijai.

Praktiskajā piemērā struktūrā tika iekļautas trīs dimensijas: laika dimensija, teritoriālā dimensija un tautības dimensija. Šāds dimensiju kopums tieši atspoguļo sākotnējo datu tabulas struktūru un nodrošina statistisko novērojumu viennozīmīgu identificēšanu. Papildus dimensijām tika definēti divi rādītāji, kas paredzēti skaitlisko vērtību glabāšanai, kā arī atribūti papildu informācijas saglabāšanai, kas sākotnējā datu kopā ir norādīta atsevišķos laukos.

Skripta realizācijā būtiska uzmanība tika pievērsta arī datu struktūras lasāmībai un semantiskajai skaidrībai. Katrai dimensijai un rādītājam tika pievienoti cilvēkam saprotami nosaukumi (rdfs:label), kas atvieglo datu interpretāciju un vaicājumu veidošanu. Šī pieeja nodrošina, ka izveidotā RDF Data Cube struktūra ir izmantojama ne tikai mašīnlasāmi, bet arī saprotama cilvēkam, analizējot datus RDF formātā.

Izveidotā RDF Data Cube struktūra kalpo kā pamats turpmākajam datu pārveides procesam, kurā no tabulārajiem datiem tiek ģenerēti statistiskie novērojumi (qb:Observation). Šāds risinājums nodrošina stingru atbilstību RDF Data Cube standartam un ļauj praktiskajā piemērā konsekventi sasaistīt visus statistiskos novērojumus ar vienotu struktūras definīciju.

3.3 Klasifikatoru integrācija un semantiskā sasaistīšana

Klasifikatori ir oficiālie Latvijas nacionālie klasifikatori kas ir atrodamī internetā vietnē⁴. Izmantotie klasifikatori ir ATVK_2021 [16] un TAUT_2016 [17]. Skriptā notiek atsevišķu failu izmantošana klasifikatoru datiem: tautību klasifikatoram (TAUT) un teritoriju klasifikatoram (ATVK), kā arī atvērto datu portāla teritoriālie kodi kuros ir LV + ATVK kodi kā arī konkrētu pilsētu un reģionu kodi, ar kuru arī tika sasaistīti dati.

Praktiskajā piemērā klasifikatoru integrācija tika īstenota ar mērķi nodrošināt, ka statistikas datu dimensiju vērtības RDF vidē tiek interpretētas kā semantiski jēdzieni ar skaidru nozīmi, nevis tikai kā tehniski kodi. Šim nolūkam tika izmantota daudzlīmeņu pieeja, kurā nošķirti datu kopā lietotie klasifikatori un Latvijas nacionālie klasifikatori, vienlaikus saglabājot iespēju tos savstarpēji sasaistīt.

Teritoriālās dimensijas gadījumā par pamata klasifikatoru tika izvēlēts atvērto datu portāla publicētais CSP teritoriju klasifikators, kas satur pilnu vērtību vārdnīcu [18]. Šis klasifikators ietver administratīvas teritorijas dažādās detalizācijas līmeņos tostarp arī tādu iedalījumus, kas nav tieši pārstāvēti ATVK klasifikācijā, piemēram, reģionu līmeni. Šāda

⁴ <https://klasis.csp.gov.lv/lv-LV>

klasifikatora izmantošana nodrošina pilnu pārklājumu visām datu kopā izmantotajām teritoriju vērtībām un atbilst datu portāla publicēšanas praksei.

Praktiskajā realizācijā teritoriju klasifikators tika ielādēts no CSV faila un pārveidots kartēšanas struktūrā, kas ļauj katrai teritorijas koda vērtībai pievienot nosaukumu latviešu un angļu valodā. Semantiskajā modelī katra teritorijas vērtība tiek reprezentēta kā SKOS jēdziens ar savu identifikatoru, notāciju un cilvēkiem saprotamu apzīmējumu. Teritoriju kodu saraksts tiek piesaistīts Data Cube teritorijas dimensijai, nodrošinot, ka novērojumos izmantotās vērtības vienmēr atsaucas uz definētu klasifikatoru.

Skripta fragmentā zemāk parādīta teritoriju klasifikatora piesaiste semantiskajam modelis un nosaukumu pievienošana no CSP vārdnīcas.

```
lv_label, en_label = ter_map.get(area_code, ("", ""))
if lv_label:
    g.add((area_uri, SKOS.prefLabel, Literal(lv_label,
lang="lv")))
if en_label:
    g.add((area_uri, SKOS.prefLabel, Literal(en_label,
lang="en")))
```

1. pirmkoda fragments

Papildus pamata klasifikatoram praktiskajā piemērā tika izmantots Latvija nacionālais administratīvo teritoriju klasifikators ATVK_2021 kā atsauces klasifikators semantiskajai sasaistīšanai. ATVK netiek izmantots kā primārais teritoriju kodu avots, bet gan kā normatīvs standarts, ar kuru tiek veidota atbilstība gadījumos, kad teritoriju vērtības ir viennozīmīgi interpretējamas kā konkrētas administratīvās vienības. Šāda pieeja ļauj saglabāt augstāku teritoriju detalizācijas līmeni, vienlaikus nodrošinot savietojamību ar citiem datu avotiem, kas balstās uz ATVK.

Semantiskā saistīšana ar ATVK tika realizēta tikai kontrolētos gadījumos, no teritorijas koda izdalot ciparu komponenti un pārbaudot tās eksistenci ATVK klasifikatorā. Ja atbilstība ir nosakāma, starp CSP teritorijas jēdzienu un ATVK jēdzienu tiek izveidota skos:exactMatch attiecība, pretējā gadījumā sasaiste netiek veidota, lai izvairītos no kļūdainas interpretācijas.

Analogā veidā tika realizēta tautību klasifikatora integrācija. Datu kopā izmantotie tautību kodi tika modelēti kā atsevišķi SKOS jēdzieni lokālajā kodu sarakstā. Kā nacionālais atsauces klasifikators tika izmantots TAUT_2016, kas nodrošina ka normatīvu tautību klasifikāciju Latvijas oficiālajā statistikā. Tā kā tautības kodi nav tieši identiski TAUT_2016 numeriskajiem kodiem tika ieviesta kartēšana, kas nosaka atbilstību tikai tām tautībām, kurās šāda atbilstība ir droši identificējama.

Koda fragments zemāk ilustrē kontrolētu sasaistes izveidi ar TAUT_2016 klasifikatoru:

```
taut_code = eth_to_taut.get(eth_code)
if taut_code and taut_code in taut_map_code_to_name:
    g.add((eth_uri, SKOS.exactMatch, taut_uri))
```

2. pirmkoda fragments

Šāda klasifikatoru integrācijas pieeja nodrošina, ka statistikas datu semantiskais modelis atspoguļo gan datu kopas praktisko struktūru, gan Latvijas nacionālo klasifikatoru semantiku. Rezultātā iegūtie dati ir piemēroti atkārtotai izmantošanai, semantiskai analīzei un integrācijai ar citiem statistikas datu avotiem, nezaudējot detalizāciju un viennozīmīgu interpretāciju.

3.4 Statistisko novērojumu ģenerēšana un datu serializācija

Pēc RDF Data Cube struktūras izveides un klasifikatoru integrācijas nākamais praktiskā piemēra posms ir statistisko novērojumu ģenerēšana no tabulārajiem datiem. Šī posma mērķis bija katru datu kopas rindu pārveidot par atsevišķu RDF Data Cube novērojumu (qb:Observation), nodrošinot, ka katrs novērojums ir viennozīmīgi saistīts ar definētajām dimensijām, rādītājiem un atribūtiem.

Praktiskajā realizācijā galvenā datu kopa tika lasīta no CSV faila un katra rinda tika interpretēta kā potenciāls statistiskais novērojums. Pirms novērojumu veidošanas tika veikta sākotnējā datu validācija, pārbaudot obligāto dimensiju vērtību esamību. Novērojumi, kuriem trūka laika, teritorijas vai tautības dimensijas vērtības, netika iekļauti semantiskajā modelī. Šāda pieeja novērš semantiski nepilnīgu novērojumu izveidi un uzlabo datu kvalitāti.

Katram derīgajam ierakstam tika izveidots unikāls novērojuma identifikators, balstoties uz datu rindas indeksu. Novērojums tika sasaistīts ar atbilstošo datu kopu un tam tika piešķirtas atsauces uz iepriekš izveidotajiem dimensiju jēdzieniem: teritoriju, laika periodu un tautību. Laika dimensija tika modelēta, izmantojot ārēju stabilu gadu identifikatoru kopa, kas ļauj nodrošināt konsekventu laika vērtību interpretāciju arī ārpus konkrētās datu kopas.

Koda fragments zemāk ilustrē novērojuma izveidi un tā sasaisti ar dimensijām:

```
obs = EX[f"obs/{idx}"]
g.add((obs, RDF.type, QB.Observation))
g.add((obs, QB.dataSet, dataset))
g.add((obs, dim_area, area_uri))
g.add((obs, dim_time, year_uri))
g.add((obs, dim_eth, eth_uri))
```

3. pirmkoda fragments

Papildus dimensijām katram novērojumam tika pievienoti arī statistiskie rādītāji. Praktiskajā piemērā tika izmantoti divi rādītāji: iedzīvotāju skaits un procentuālais īpatsvars. Rādītāju vērtības tika pārveidotas uz atbilstošiem XML Schema datu tiem (xsd:integer un

xsd:decimal), lai nodrošinātu konkrētu skaitlisko datu interpretāciju un iespēju veikt skaitliskas operācijas SPARQL vaicājumos.

Tika apstrādāti arī atribūti, kas satur papildu informāciju vai piezīmes par mērījumiem. Šie atribūti tika pievienoti tikai gadījumos, kad to vērtības bija pieejamas, tādējādi saglabājot datu reprezentācijas elastību un izvairoties no lieku trijnieku ģenerēšanas.

Koda fragments zemāk ilustrē rādītāju pievienošanu novērojumam ar atbilstošiem datu tipiem:

```
if not pd.isna(ymb):
    g.add((obs, m_ymb, Literal(int(ymb),
datatype=XSD.integer)))

if not pd.isna(pc):
    g.add((obs, m_pc, Literal(float(pc),
datatype=XSD.decimal)))
```

4. pirmkoda fragments

Nemot vērā lielo datu apjomu, praktiskajā realizācijā tika ieviests kešošanas algoritms, lai izvairītos no atkārtotas vienādu klasifikatoru jēdzienu izveides. Šāda pieeja samazināja ģenerēto RDF trijnieku skaitu un uzlaboja skripta izpildes efektivitāti, vienlaikus saglabājot semantiskā modeļa korektumu.

Noslēgumā izveidotais RDF grafiks tika serializēts Turtle formātā un saglabāts kā atsevišķa datne. Šis formāts tika izvēlēts tā lasāmības un plašā atbalsta dēļ semantiskā tīmekļa rīkos. Rezultātā tika iegūta datne, kura satur pilnu RDF Data Cube reprezentāciju, kas ietver datu kopas metadatus, struktūras definīciju, klasifikatorus un visus statistiskos novērojumus, un ir tieši izmantojams turpmākai publicēšanai atvērto saistīto datu formātā.

3.5 Datu publicēšana atvērto saistīto datu formātā

Izstrādātās metodoloģijas praktiskās realizācijas noslēdzošais posms bija sagatavoto RDF Data Cube datu publicēšana atvērto saistīto datu formātā. Šī posma mērķis bija nodrošināt, ka izveidotā statistikas datu kopa ir publiski pieejama, identificējama ar stabilām tīmekļa adresēm un izmantojama gan cilvēkiem, gan automatizētiem rīkiem.

Praktiskajā piemērā dati tika publicēti kā statistiska RDF resursu kopa, izmantojot tīmekļa vietni⁵. Šāda pieeja ļauj nodrošināt datu publisku pieejamību bez sarežģītas servera infrastruktūras. Vienlaikus jāatzīmē, ka izmantotie URI praktiskajā piemērā nav pilnībā dereferencējami, jo tie neatgriež resursu aprakstus atbilstoši satura vienošanās (content negotiation) principam. Līdz ar to publicētais risinājums atbilst atvērto datu publicēšanas pamatprasībām, bet tikai daļēji realizē atvērto saistīto datu ideālo publicēšanas modeli.

⁵ <https://niklavsp.github.io/tautiba-rdf-datacube/>

Tika publicēti arī datu kopas metadati⁶, kas nodrošina pamatinformāciju par datu saturu, izcelsmi un izmantošanas nosacījumiem. Metadatu aprakstā ir iekļauts datu kopas nosaukums, apraksts, publicētājs, licence un norāde uz vietni, kur dati ir pieejami. Šāds metadatu minimums ir pietiekams, lai datu kopa būtu identificējama un atkārtoti izmantojama atvērto datu kontekstā.

Publicētā tīmekļa vietne kalpo kā cilvēkam draudzīgs piekļuves punkts, kas ļauj iepazīties ar datu kopas struktūru un saturu, vienlaikus saglabājot iespēju tieši piekļūt RDF datnēm. Šāda pieeja nodrošina līdzsvaru starp cilvēklasāmu un mašīnlasāmu datu pieejamību, kas ir būtisks atvērto saistīto datu publicēšanas aspekts.

Lai gan praktiskajā piemērā netika izveidots atsevišķs SPARQL vaicājumu galapunkts, publicētie dati ir pilnībā saderīgi ar RDF Data Cube standartu un var tikt analizēti, izmantojot jebkuru RDF un SPARQL atbalstošu rīku. Tas nozīmē, ka datu publicēšanas risinājums ir paplašināms un pielāgojams turpmākai izmantošanai, ja būtu nepieciešams nodrošināt dinamisku vaicājumu izpildi tiešsaistē.

Kopumā praktiskajā piemērā realizētā publicēšanas pieeja demonstrē, ka statistikas datus iespējams publicēt atvērto saistīto datu formātā arī ar ierobežotiem tehniskajiem resursiem. Izvēlētais risinājums ir pietiekams metodoloģijas demonstrācijai un apliecina, ka RDF Data Cube standarta izmantošana ir praktiski realizējama reālā atvērto datu publicēšanas kontekstā.

⁶ <https://github.com/NiklavsPS/tautiba-rdf-datacube/blob/main/metadata.ttl>

REZULTĀTI

Šī kursa darba praktiskās daļas rezultātā tika izveidota semantiski strukturēta statistikas datu kopa par iedzīvotāju skaitu pēc tautības, izmantojot RDF Data Cube standartu. Sākotnēji tabulārā formātā publicētie statistikas dati tika pārveidoti RDF formātā, saglabājot to daudzdimensionālo struktūru un nodrošinot viennozīmīgu novērojumu aprakstu.

Izveidotajā datu kopā katrs statistiskais novērojums ir modelēts kā atsevišķs qb:Observation objekts, kurš ir sasaistīts ar konkrētu teritoriju, laika periodu un tautības kategoriju. Teritoriālā dimensija balstīta uz Centrālās statistikas pārvaldes atvērto datu portāla klasifikatoru teritorijas, kas nodrošina detalizētu administratīvo teritoriju pārklājumu. Papildus tam atsevišķām teritorijām tika izveidota semantiska sasaiste ar Latvijas nacionālo administratīvo teritoriju klasifikatoru ATVK_2021.

Tautību dimensijā tika izmantoti datu kopā esošie tautību kodi, kuri semantiski sasaistīti ar TAUT_2016 nacionālo klasifikatoru gadījumos, kad bija iespējams nodrošināt viennozīmīgu atbilstību. Šī sasaistīšana tika realizēta, modelējot klasifikatoru vērtības kā SKOS jēdzienus un izmantojot semantiskās atbilstības attiecības.

Datu kopas struktūra tika veidota, izmantojot datu struktūras definīciju (Data Structure Definition), kurā ir noteiktas izmantotās dimensijas, rādītāji un atribūti. Rādītāji ietver gan absolūto iedzīvotāju skaitu, gan procentuālo īpatsvaru, savukārt atribūti tiek izmantoti papildu informācijas pievienošanai atsevišķiem mērījumiem.

Izveidotā RDF Data Cube datu kopa tika publicēta tīmeklī kā statiska RDF datne ar stabiliem URI. Dati ir pieejami lejupielādei un izmantojami turpmākai analīzei ar RDF atbalstošiem rīkiem. Publicētajā risinājumā URI nav pilnībā dereferencējami, tomēr tie nodrošina konsekventu resursu identificēšanu un sasaisti datu kopas ietvaros.

SECINĀJUMI

Kursa darba mērķis bija izstrādāt un praktiski pārbaudīt metodoloģiju statistikas datu pārveidei un publicēšanai atvērto saistīto datu formātā, izmantojot RDF Data Cube standartu. Izvirzītais mērķis darba gaitā tika sasniegts, jo tika izveidota pilnvērtīga semantiska statistikas datu reprezentācija, kas balstīta uz reāliem Centrālās statistikas pārvaldes atvērto datu piemēriem.

Darba rezultāti liecina, ka RDF Data Cube standarts ir piemērots daudzdimensionālu statistikas datu strukturēšanai, jo tas nodrošina skaidru novērojumu, dimensiju un rādītāju nošķirumu, kā arī viennozīmīgu statistisko datu interpretāciju neatkarīgi no to sākotnējās tabulārās formas.

Būtisks ieguvums praktiskajā piemērā ir klasifikatoru integrācija, kas tika realizēta, izmantojot gan atvērto datu portāla teritoriju klasifikatoru ar augstu detalizācijas līmeni, gan Latvijas nacionālos klasifikatorus ATVK_2021 un TAUT_2016. Šāda daudzlīmeņu pieeja ļāva saglabāt datu kopas sākotnējo struktūru un detalizāciju, vienlaikus nodrošinot semantisku sasaisti ar klasifikatoriem. Tas apliecina, ka praksē ir lietderīgi nodalīt datu publicēšanas vajadzībām pielāgotus klasifikatorus no oficiālajiem atsauces klasifikatoriem.

Vienlaikus darba gaitā tika identificēti arī praktiskās realizācijas ierobežojumi. Publicētajā risinājumā izmantotie URI nav pilnībā dereferencējami un neatbalsta satura sarunu (content negotiation), kas nozīmē, ka datu publicēšana tikai daļēji atbilst ideālajam atvērto saistīto datu publicēšanas modelim. Šis ierobežojums ir saistīts ar izvēlēto vienkāršoto publicēšanas pieeju un tehniskās infrastruktūras ierobežojumiem.

Izveidotā RDF Data Cube datu kopa uzskatāma par pamatu turpmākai statistikas datu analīzei un integrācijai ar citiem atvērto saistīto datu resursiem, tomēr šo iespēju praktiska izmantošana, piemēram, interaktīvu vaicājumu, vizualizāciju vai lietotņu izstrāde, pārsniedz šī kursa darba ietvarus.

Darba ietvaros izstrādātā metodoloģija un praktiskais piemērs parāda, ka statistikas datu publicēšana atvērto saistīto datu formātā ir realizējama arī ar ierobežotiem tehniskajiem resursiem. Vienlaikus secināms, ka pilnīgākai atbilstībai atvērto saistīto datu principiem nākotnē būtu lietderīgi ieviest dereferencējamus URI, SPARQL vaicājumu galapunktu un pilnīgāku DCAT metadatu profilu.

Noslēgumā var secināt, ka kursa darba rezultāti apliecina RDF Data Cube standarta praktisko pielietojamību statistikas datu publicēšanā un sniedz pamatu turpmākiem pētījumiem un risinājumu attīstībai semantiskā tīmekļa un atvērto statistikas datu jomā.

IZMANTOTĀ LITERATŪRA

- [1] Centrālā statistikas pārvalde. „Iedzīvotāju skaits pēc tautības” [tiešsaiste]. Latvijas atvērto datu portāls data.gov.lv. [Piekļūts: 20.12.2025].
Pieejams: <https://data.gov.lv/dati/lv/dataset/tautiba/resource/ac7b0734-bba7-4295-a81a-1eb635d722bc>.
- [2] Berners-Lee T., Hendler J., Lassila O. The Semantic Web // Scientific American. – 2001. – Vol. 284, No. 5. – P. 34–43.
- [3] John Cardiff. A Revised Semantic Web Layer Cake [Bilde].
Pieejams: https://www.researchgate.net/figure/A-Revised-Semantic-Web-LayerCake_fig3_228533759.
- [4] Heath T., Bizer C. Linked Data: Evolving the Web into a Global Data Space. – San Rafael, CA: Morgan & Claypool, 2011. – 165 lpp.
- [5] Berners-Lee T. Linked Data – Design Issues [tiešsaiste]. – 2006.
[Piekļūts: 20.12.2025].
Pieejams: <https://www.w3.org/DesignIssues/LinkedData.html>.
- [6] Klyne G., Carroll J. Resource Description Framework (RDF): Concepts and Abstract Syntax [tiešsaiste]. W3C Recommendation 10 February 2004.
Pieejams: <https://www.w3.org/TR/2004/REC-rdf-concepts-20040210/>.
- [7] European Commission. Creating Value through Open Data [tiešsaiste]. – 2015.
[Piekļūts: 20.12.2025]. Pieejams:
https://data.europa.eu/sites/default/files/edp_creating_value_through_open_data_0.pdf.
- [8] Schreiber G., Raimond Y. RDF 1.1 Primer [tiešsaiste]. W3C Working Group Note 24 June 2020. Pieejams: <https://www.w3.org/TR/rdf-primer/>.
- [9] Brickley D., Guha R. RDF Schema 1.1 [tiešsaiste]. W3C Recommendation 25 February 2014. Pieejams: <https://www.w3.org/TR/rdf-schema/>.
- [10] Bizer C., Heath T., Berners-Lee T. Linked Data – The Story So Far // International Journal on Semantic Web and Information Systems. – 2009. – Vol. 5, No. 3. – P. 1–23.
- [11] Cyganiak R., Reynolds D., Tennison J. RDF Data Cube 1.0 [tiešsaiste]. W3C Recommendation 27 August 2014.
Pieejams: <https://www.w3.org/TR/vocab-data-cube/>.

- [12] Eurostat. Linked open data [tiešsaiste]. Statistics Explained. [Piekļūts: 20.12.2025]. Pieejams: https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Linked_open_data.
- [13] OECD, Eurostat. SDMX Technical Standards — Information Model [tiešsaiste]. – 2022. [Piekļūts: 26.12.2025].
Pieejams: https://sdmx.org/?page_id=3215.
- [14] Miles A., Bechhofer S. SKOS Simple Knowledge Organization System Reference [tiešsaiste]. W3C Recommendation 18 August 2009.
Pieejams: <https://www.w3.org/TR/skos-reference/>.
- [15] Eriksson H. Digitizing curricula: an approach for digital usability // Proceedings of the eChallenges e-2015 Conference. – 2015. DOI: 10.1109/eCHALLENGES.2015.7441086.
- [16] Centrālā Statistikas pārvalde. ATVK_2021: Administratīvo teritoriju un teritoriālā iedalījuma vienību klasifikators, 2021. gada versija [tiešsaiste]. [Piekļūts: 05.01.2026]. Pieejams: <https://klasis.csp.gov.lv/lv-LV/classifications/ATVK2021>.
- [17] Centrālā Statistikas pārvalde. TAUT_2016: Tautību klasifikators [tiešsaiste]. [Piekļūts: 05.01.2026].
Pieejams: <https://klasis.csp.gov.lv/lv-LV/classifications/TAUT2016>.
- [18] Centrālā Statistikas pārvalde. Teritorijas [tiešsaiste]. Latvijas atvērto datu portāls data.gov.lv. [Piekļūts: 05.01.2026].
Pieejams: https://data.gov.lv/dati/dataset/teritorijas_csb.
- [19] Semantic Arts, “How to Use SPARQL with TARQL for CSV to RDF” [Bilde].
Pieejams: <https://www.semanticarts.com/how-to-sparql-with-tarql/>
- [20] Stardog Documentation, *RDF Graph Data Model* [Bilde].
Pieejams: <https://docs.stardog.com/tutorials/rdf-graph-data-model>

PIELIKUMI

1. Pielikums

```
import re
import pandas as pd
from rdflib import Graph, Namespace, URIRef, Literal
from rdflib.namespace import RDF, RDFS, XSD, DCTERMS
from slugify import slugify

CSV_PATH = "data/tautiba.csv"
TAUT_PATH = "data/TAUT2016_11012026_015802.csv"
ATVK_PATH = "data/ATVK2021_11012026_015924.csv"
TER_PATH = "data/teritorijas.csv"
OUT_TTL = "tautiba_datacube.ttl"

COL_AREA = "AllAreaLV"
COL_TIME = "TIME"
COL_ETH = "ETHNICITY"

MEASURE_NUMB = "NUMB"
MEASURE_PC = "PC"
ATTR_NUMB_X = "NUMB_X"
ATTR_PC_X = "PC_X"

QB = Namespace("http://purl.org/linked-data/cube#")
SKOS = Namespace("http://www.w3.org/2004/02/skos/core#")

EX = Namespace("https://niklavspis.github.io/tautiba-rdf-
datacube/")
YEAR =
Namespace("http://reference.data.gov.uk/id/gregorian-year/")

g = Graph()
g.bind("qb", QB)
g.bind("skos", SKOS)
g.bind("ex", EX)
g.bind("rdfs", RDFS)
g.bind("dcterm", DCTERMS)

def slug(v: str) -> str:
    return slugify(str(v), lowercase=True)

def extract_digits(s: str):
    nums = re.findall(r"\d+", str(s))
    return int("".join(nums)) if nums else None
```



```

def to_int_or_none(x: str):
    try:
        return int(str(x).strip())
    except:
        return None

def read_csv_robust(path: str, sep_candidates=(",", ";",
"\t"), **kwargs) -> pd.DataFrame:
    """
    Nolasā CSV ar dažādiem atdalītājiem
    (komats/semikols/tab).
    """
    last_err = None
    for sep in sep_candidates:
        try:
            return pd.read_csv(path, sep=sep, **kwargs)
        except Exception as e:
            last_err = e
    raise last_err

taut_df = pd.read_csv(TAUT_PATH, dtype=str).fillna("")
atvk_df = pd.read_csv(ATVK_PATH, dtype=str).fillna("")

taut_map_code_to_name = {}
for _, r in taut_df.iterrows():
    kods = to_int_or_none(r.get("Kods", ""))
    nos = str(r.get("Nosaukums", "")).strip()
    if kods is not None and nos:
        taut_map_code_to_name[kods] = nos

atvk_map_code_to_name = {}
for _, r in atvk_df.iterrows():
    kods = to_int_or_none(r.get("Kods", ""))
    nos = str(r.get("Nosaukums", "")).strip()
    if kods is not None and nos:
        atvk_map_code_to_name[kods] = nos

ter_df = read_csv_robust(TER_PATH, dtype=str,
encoding="utf-8-sig").fillna("")

ter_map = {}
for _, r in ter_df.iterrows():
    code = str(r.get("ValueCode", "")).strip()
    lv = str(r.get("ValueTextL", "")).strip()
    en = str(r.get("ValueTextL_Eng", "")).strip()
    if code:
        ter_map[code] = (lv, en)

```

```

eth_to_taut = {
    "E_LAT": 1,
    "E_LIT": 2,
    "E_EST": 3,
    "E_AZE": 12,
    "E_BRU": 13,
    "E_GEO": 14,
    "E_ARM": 15,
    "E_RUS": 17,
    "E_MOL": 18,
    "E_UKR": 21,
    "E_UZB": 22,
    "E_POL": 45,
    "E_JEW": 68,
    "E_TTR": 242,
    "E_ROM": 313,
    "E_IND": 295,
}

dataset = EX["dataset/tautiba"]
dsd = EX["dsd/tautiba"]

dim_area = EX["dim/refArea"]
dim_time = EX["dim/refPeriod"]
dim_eth = EX["dim/ethnicity"]

m_numb = EX["measure/numb"]
m_pc = EX["measure/pc"]

a_numb_x = EX["attr/numb_x"]
a_pc_x = EX["attr/pc_x"]

g.add((dataset, RDF.type, QB.DataSet))
g.add((dataset, RDFS.label, Literal("Iedzīvotāju skaits pēc
tautības (RDF Data Cube)", lang="lv")))
g.add((dataset, DCTERMS.title, Literal("Population by
ethnicity (RDF Data Cube)", lang="en")))
g.add((dataset, QB.structure, dsd))

g.add((dsd, RDF.type, QB.DataStructureDefinition))

def add_component_dimension(dimension_uri):
    cs = URIRef(str(dsd) + "/component/" +
slug(str(dimension_uri).split("/")[-1]))
    g.add((dsd, QB.component, cs))
    g.add((cs, QB.dimension, dimension_uri))

def add_component_measure(measure_uri):
    cs = URIRef(str(dsd) + "/component/" +
slug(str(measure_uri).split("/")[-1]))

```

```

        g.add((dsd, QB.component, cs))
        g.add((cs, QB.measure, measure_uri))

    def add_component_attribute(attr_uri):
        cs = URIRef(str(dsd) + "/component/" +
slug(str(attr_uri).split("/")[-1]))
        g.add((dsd, QB.component, cs))
        g.add((cs, QB.attribute, attr_uri))

    add_component_dimension(dim_area)
    add_component_dimension(dim_time)
    add_component_dimension(dim_eth)
    add_component_measure(m_numb)
    add_component_measure(m_pc)
    add_component_attribute(a_numb_x)
    add_component_attribute(a_pc_x)

    g.add((dim_area, RDF.type, QB.DimensionProperty))
    g.add((dim_area, RDFS.label, Literal("Teritorija",
lang="lv"))))

    g.add((dim_time, RDF.type, QB.DimensionProperty))
    g.add((dim_time, RDFS.label, Literal("Gads", lang="lv"))))

    g.add((dim_eth, RDF.type, QB.DimensionProperty))
    g.add((dim_eth, RDFS.label, Literal("Tautība", lang="lv"))))

    g.add((m_numb, RDF.type, QB.MeasureProperty))
    g.add((m_numb, RDFS.label, Literal("Skaitis", lang="lv"))))
    g.add((m_numb, RDFS.label, Literal("Number", lang="en"))))

    g.add((m_pc, RDF.type, QB.MeasureProperty))
    g.add((m_pc, RDFS.label, Literal("%", lang="lv"))))
    g.add((m_pc, RDFS.label, Literal("per cent", lang="en"))))

    g.add((a_numb_x, RDF.type, QB.AttributeProperty))
    g.add((a_numb_x, RDFS.label, Literal("NUMB
papildu/atzīmes", lang="lv"))))

    g.add((a_pc_x, RDF.type, QB.AttributeProperty))
    g.add((a_pc_x, RDFS.label, Literal("PC papildu/atzīmes",
lang="lv"))))

    scheme_area = EX["codelist/area"]
    scheme_eth = EX["codelist/ethnicity"]

    g.add((scheme_area, RDF.type, SKOS.ConceptScheme))
    g.add((scheme_area, RDFS.label, Literal("Teritoriju kodu
saraksts (CSP atvērtu datu teritorijas)", lang="lv"))))
    g.add((scheme_area, RDFS.label, Literal("Territory code
list (CSB open data territories)", lang="en"))))

```

```

g.add((scheme_eth, RDF.type, SKOS.ConceptScheme))
g.add((scheme_eth, RDFS.label, Literal("Tautību kodu
saraksts (ETHNICITY)", lang="lv")))

g.add((dim_area, QB.codeList, scheme_area))
g.add((dim_eth, QB.codeList, scheme_eth))

scheme_atvk_official = EX["classifier/atvk2021"]
scheme_taut_official = EX["classifier/taut2016"]

g.add((scheme_atvk_official, RDF.type, SKOS.ConceptScheme))
g.add((scheme_atvk_official, RDFS.label, Literal("ATVK 2021
(klasifikators)", lang="lv")))

g.add((scheme_taut_official, RDF.type, SKOS.ConceptScheme))
g.add((scheme_taut_official, RDFS.label, Literal("TAUT 2016
(klasifikators)", lang="lv")))

df = pd.read_csv(CSV_PATH, sep=";")

for col in [MEASURE_NUMB, MEASURE_PC, ATTR_NUMB_X,
ATTR_PC_X, COL_TIME]:
    df[col] = pd.to_numeric(df[col], errors="coerce")

area_seen = set()
eth_seen = set()
atvk_seen = set()
taut_seen = set()

for idx, row in df.iterrows():
    area_code = row.get(COL_AREA)
    eth_code = row.get(COL_ETH)
    year_val = row.get(COL_TIME)

    if pd.isna(year_val) or pd.isna(area_code) or
pd.isna(eth_code):
        continue

    area_code = str(area_code).strip()
    eth_code = str(eth_code).strip()

    year_uri = YEAR[str(int(year_val))]

    area_id = area_code.lower()
    area_uri = EX[f"concept/area/{area_id}"]

    if area_id not in area_seen:
        area_seen.add(area_id)
        g.add((area_uri, RDF.type, SKOS.Concept))

```

```

        g.add((area_uri, SKOS.inScheme, scheme_area))
        g.add((area_uri, SKOS.notation,
Literal(area_code)))

        lv_label, en_label = ter_map.get(area_code, ("",
""))

        if lv_label:
            g.add((area_uri, SKOS.prefLabel,
Literal(lv_label, lang="lv")))
        if en_label:
            g.add((area_uri, SKOS.prefLabel,
Literal(en_label, lang="en")))
        if not lv_label and not en_label:
            g.add((area_uri, SKOS.prefLabel,
Literal(area_code)))

        area_digits = extract_digits(area_code)
        if area_digits and area_digits in
atvk_map_code_to_name:
            atvk_uri =
EX[f"concept/atvk2021/{area_digits}"]

            if area_digits not in atvk_seen:
                atvk_seen.add(area_digits)
                g.add((atvk_uri, RDF.type, SKOS.Concept))
                g.add((atvk_uri, SKOS.inScheme,
scheme_atvk_official))
                g.add((atvk_uri, SKOS.notation,
Literal(str(area_digits))))
                g.add((atvk_uri, SKOS.prefLabel,
Literal(atvk_map_code_to_name[area_digits], lang="lv")))

            g.add((area_uri, SKOS.exactMatch, atvk_uri))

        eth_id = eth_code.lower()
        eth_uri = EX[f"concept/ethnicity/{eth_id}"]

        if eth_id not in eth_seen:
            eth_seen.add(eth_id)
            g.add((eth_uri, RDF.type, SKOS.Concept))
            g.add((eth_uri, SKOS.inScheme, scheme_eth))
            g.add((eth_uri, SKOS.notation, Literal(eth_code)))

        taut_code = eth_to_taut.get(eth_code)
        if taut_code and taut_code in
taut_map_code_to_name:
            g.add((eth_uri, SKOS.prefLabel,
Literal(taut_map_code_to_name[taut_code], lang="lv")))

            taut_uri = EX[f"concept/taut2016/{taut_code}"]
            if taut_code not in taut_seen:
                taut_seen.add(taut_code)

```

```

        g.add((taut_uri, RDF.type, SKOS.Concept))
        g.add((taut_uri, SKOS.inScheme,
scheme_taut_official))
        g.add((taut_uri, SKOS.notation,
Literal(str(taut_code))))
        g.add((taut_uri, SKOS.prefLabel,
Literal(taut_map_code_to_name[taut_code], lang="lv")))

        g.add((eth_uri, SKOS.exactMatch, taut_uri))
    else:
        g.add((eth_uri, SKOS.prefLabel,
Literal(eth_code)))

    obs = EX[f"obs/{idx}"]
    g.add((obs, RDF.type, QB.Observation))
    g.add((obs, QB.dataSet, dataset))

    g.add((obs, dim_area, area_uri))
    g.add((obs, dim_time, year_uri))
    g.add((obs, dim_eth, eth_uri))

    numb = row.get(MEASURE_NUMB)
    pc    = row.get(MEASURE_PC)
    if not pd.isna(numb):
        g.add((obs, m_numb, Literal(int(numb),
datatype=XSD.integer)))
    if not pd.isna(pc):
        g.add((obs, m_pc, Literal(float(pc),
datatype=XSD.decimal)))

    numb_x = row.get(ATTR_NUMB_X)
    pc_x    = row.get(ATTR_PC_X)
    if not pd.isna(numb_x):
        g.add((obs, a_numb_x, Literal(int(numb_x),
datatype=XSD.integer)))
    if not pd.isna(pc_x):
        g.add((obs, a_pc_x, Literal(int(pc_x),
datatype=XSD.integer)))

    g.serialize(destination=OUT_TTL, format="turtle")
    print(f"OK: saved {OUT_TTL} | triples: {len(g)}")

```

DOKUMENTĀRĀ LAPA

Kursa darbs „Statistikas datu pārveide un publicēšana atvērto saistīto datu formā “ ir izstrādāts LU Eksakto zinātņu un tehnoloģiju fakultātē Datorikas nodaļā.

Ar savu parakstu (drošs elektroniskais paraksts) apliecinu, ka pētījums veikts patstāvīgi un izmantoti tikai tajā norādītie informācijas avoti.

Autors: (drošs elektroniskais paraksts) Niklāvs Pauls Strazdiņš (stud. apl. Nr. ns22033).

Darba vadītājs: (drošs elektroniskais paraksts) Dr. dat. Uldis Bojārs.

Darbs augšupielādēts LUIS 15.01.2026.